



Derin Öğrenme: Büyük Veri için Tahmin Modellerine Giriş

Yapay zeka ve makine öğreniminde yeni bir öğrenme paradigması olarak ortaya çıkan derin öğrenme modelleri, görüntü analizi ve konuşma tanıma gibi alanlarda kayda değer başarılar elde etti. Bu sunumda, derin öğrenmenin temel mimari yapılarını ve uygulama alanlarını inceleyeceğiz.

Derin Öğrenmenin Tarihsel Gelişimi

Yapay sinir ağlarının tarihi uzun ve karmaşık bir gelişim sürecini içerir. 1943'te McCulloch ve Pitts'in ilk matematiksel nöron modelini oluşturmasıyla başlayan bu yolculuk, 2006'da derin öğrenme kavramının popülerleşmesine kadar uzanır.

1

1943-1957: Temeller

McCulloch-Pitts nöron modeli ve Rosenblatt'ın Perceptron'u ile yapay sinir ağlarının temelleri atılır.

2

1969-1986: AI Kışı

Minsky ve Papert'in XOR problemi analizi nedeniyle sinir ağları araştırmalarında bir duraklama yaşanır.

3


1986-1997: İkinci Dalga

Backpropagation algoritması ve Neocognitron'un tanıtılmasıyla sinir ağları araştırmaları yeniden canlanır.

4

2006-Günümüz: Derin Öğrenme Devrimi

Hinton ve ekibinin Deep Belief Networks çalışması ile derin öğrenme çağı başlar ve görüntü tanıma, doğal dil işleme gibi alanlarda devrim yaratır.



Yapay Sinir Ağı Mimarileri: Temel Yapılar


Yapay Nöron Modeli

Her sinir ağının temel yapı taşı, girdi vektörü **x**, ağırlık vektörü **w** ve bias **b** ile temsil edilen bir yapay nöron modelidir. Bu bileşenler birlikte toplanır ve aktivasyon fonksiyonu ϕ ile işlenerek nöronun çıktısını üretir.

Çıktı hesaplaması: $y = \phi(w^T x + b)$

Temel Aktivasyon Fonksiyonları

- **ReLU:** En popüler aktivasyon fonksiyonu, derin ağlarda tercih edilir
- **Sigmoid:** Çıktıları (0,1) aralığında sınırlar
- **Tanh:** Çıktıları (-1,1) aralığında sınırlar
- **Softmax:** Son katmanda sınıflandırma için kullanılır



Derin İleri Beslemeli Sinir Ağları (D-FFNN)

Evrensel Yaklaşım Teoremi

Tek gizli katmanlı bir FFNN, yeterli nöron sayısı ile herhangi bir sürekli fonksiyonu yaklaşık olarak temsil edebilir.

Neden Derin?

Tek katmanlı ağlar teorik olarak yeterli olsa da, derin ağlar öğrenmeyi pratik kılacak algoritmalar sağlar.

Öğrenme Algoritması

Backpropagation ve Stochastic Gradient Descent ile parametreler optimize edilir.

Derin İleri Beslemeli Sinir Ağları (D-FFNN), geleneksel sinir ağlarının derin versiyonlarıdır. Bu ağlar, girdi katmanından çıktı katmanına tek yönlü bilgi akışı sağlar ve döngüsel bağlantı içermez. Her katmandaki nöronlar bir sonraki katmandaki tüm nöronlara bağlıdır, bu nedenle "tamamen bağlı" (fully connected) olarak adlandırılır.

Konvolüsyonel Sinir Ağları (CNN)

CNN'ler, görüntü ve video analizi için özel olarak tasarlanmış sinir ağlarıdır. Geleneksel FFNN'lardan farklı olarak, yerel bağlantılar ve ağırlık paylaşımı gibi özellikler içerir.



Konvolüsyon Katmanları

Kernels (filtreler) girdi üzerinde kayarak yerel özellikleri çıkarır ve aktivasyon haritaları oluşturur.



Pooling Katmanları

Max-pooling gibi yöntemlerle boyut azaltılır ve mekansal değişmezlik sağlanır.



Yerel Bağlantılar

Her nöron sadece girdinin yerel bir bölgesine bağlıdır, bu da parametre sayısını azaltır.



Ağırlık Paylaşımı

Aynı kernel tüm girdi üzerinde kullanılır, bu da hesaplama verimliliği sağlar.

CNN'nin Önemli Varyantları

1

VGGNet

Derinliğin performans üzerindeki etkisini araştıran VGGNet, 19 katmanlı mimarisiyle önceki 11 katmanlı AlexNet'ten daha iyi sonuçlar elde etti. 3×3 konvolüsyon katmanlarını üst üste ekleyerek büyük filtrelerin etkisini yakaladı.

2

GoogLeNet (Inception)


Inception mimarisi, farklı boyutlardaki filtreleri paralel olarak kullanarak ağın seyrek olmasını sağlarken hızlı matris hesaplamalarından faydalanır. Bu yaklaşım, daha az parametre ile daha iyi performans sağlar.

3


ResNet

Kalıntı öğrenme (residual learning) framework'ü ile derinlik sorununu çözen ResNet, skip connections kullanarak çok derin ağların (152 katman) eğitilmesini mümkün kıldı ve ILSVRC2016'da %3.57 hata oranı elde etti.

Neural



Puonod



Derin İnanç Ağları (DBN) ve Autoencoder'lar

Derin İnanç Ağları (DBN)

DBN'ler, Restricted Boltzmann Machines (RBM) ve Derin FFNN'lerin birleşiminden oluşan karmaşık modellerdir. İki aşamalı bir eğitim süreci kullanırlar:

1. **Ön-Eğitim (Unsupervised):** RBM'ler kullanılarak model parametreleri unsupervised şekilde başlatılır
2. **Fine-Tuning (Supervised):** Backpropagation ile supervised fine-tuning yapılır

Bu iki aşamalı yaklaşım, derin ağların eğitilmesini daha verimli hale getirir.

Autoencoder'lar


Autoencoder'lar, unsupervised öğrenme için kullanılan sinir ağlarıdır ve boyut azaltma veya özellik seçimi gibi görevlerde kullanılırlar.

Temel fikir: Girdi desenini x yeni bir kodlama $c = h(x)$ ile temsil etmeyi öğrenir ve ideal olarak çıktı deseninin girdiyle aynı olmasını sağlar: $x \approx y = g(c)$

PCA gibi lineer dönüşümlerden farklı olarak, Autoencoder'lar non-lineer dönüşümler uygulayabilir ve genellikle daha iyi performans gösterir.

Uzun Kısa Vadeli Bellek Ağları (LSTM)

LSTM'ler, RNN'lerin uzun vadeli bağımlılıkları işleme konusundaki eksikliğini gideren özel bir RNN türüdür. Gradient kaybolması veya patlaması problemini önler ve diziler üzerinde etkili çalışır.



Girdi Kapısı

Hücreye hangi yeni bilgilerin gireceğini kontrol eder



Hücre Durumu

Uzun süreli bellek CEC mekanizması ile korunur



Çıktı Kapısı

Hücreden hangi bilgilerin çıkacağını kontrol eder




Forget Kapısı

Önceki adımlardan hangi bilgilerin unutulacağını belirler


LSTM'ler, konuşma ve video verisi gibi dizileri işleyebilir ve tek veri noktaları yerine veri dizileri üzerinde çalışır. Bu özellik, metin sınıflandırma, dil çevirisi ve görüntü etiketleme gibi görevlerde yaygın olarak kullanılmalarını sağlar.

Uygulama Alanları ve Model Seçimi



Tıbbi Görüntüleme

CNN'ler deri kanseri sınıflandırmasında dermatolog seviyesinde doğruluk elde etti



Doğal Dil İşleme

LSTM ve CNN'ler metin sınıflandırma, dil çevirisi ve duygu analizinde kullanılır



Konuşma Tanıma

DBN'ler ve LSTM'ler akustik modelleme için başarılı sonuçlar üretti



Hesaplamalı Biyoloji

Gen ifade verilerinin sınıflandırılması ve RNA-protein etkileşimlerinin tahmini

Model seçiminde dikkat edilmesi gereken noktalar: CNN'ler görüntü ve dizi verilerinde etkili, LSTM'ler sıralı verilerde başarılı, D-FFNN'ler ise ilaç toksisitesi tahmini gibi geleneksel görevlerde üstün performans gösteriyor.

Sonuç ve Önemli Hususlar



Modüler Yapı

Derin öğrenme modelleri LEGO gibi esnek şekilde birleştirilebilir ve yeni uygulama özel mimariler oluşturulabilir.



Büyük Veri Gereksinimi

Derin öğrenme modelleri, binlerce örnek gerektirir. Küçük veri setlerinde performansı düşebilir.



Kara Kutu Modeller

Çoğu derin öğrenme modeli yorumlanabilir olmayan tahmin modelleridir. XAI araştırmaları bu konuda ilerleme kaydediyor.

Derin öğrenme, yapay zeka ve makine öğreniminde temel bir paradigma değişikliği yarattı. Görüntü tanıma, doğal dil işleme, konuşma tanıma ve hesaplamalı biyoloji gibi alanlarda kayda değer başarılar elde edildi. Ancak, bu modellerin etkili kullanılması için yeterli veri miktarı, uygun model seçimi ve dikkatli değerlendirme gereklidir.